

Penjelasan Dataset & Model — Titanic Classifier

1. Dataset: Titanic

Asal Usul

Dataset Titanic adalah salah satu dataset paling terkenal di dunia machine learning. Berisi data penumpang kapal RMS Titanic yang tenggelam pada 15 April 1912 setelah menabrak gunung es di Samudra Atlantik Utara. Dari 2.224 penumpang dan kru, sekitar 1.500 jiwa meninggal dunia.

Dataset ini populer karena:

- Ukurannya sedang (cocok untuk pembelajaran)
- Memiliki campuran fitur numerik dan kategorikal
- Target variabelnya binary (selamat / tidak)
- Konteks ceritanya menarik dan mudah dipahami

Sumber asli: Kompetisi Kaggle — [Titanic: Machine Learning from Disaster](#)

Fitur yang Digunakan

Dari dataset asli, dipilih **6 fitur** yang paling relevan dan tidak memiliki banyak nilai kosong:

Fitur	Tipe	Deskripsi	Alasan Dipilih
Pclass	Ordinal (1,2,3)	Kelas tiket penumpang	Kelas tiket sangat memengaruhi akses ke sekoci
Sex	Binary (0,1)	Jenis kelamin	"Wanita dan anak-anak dahulu" — kebijakan evakuasi nyata
Age	Numerik (float)	Usia penumpang	Anak-anak diprioritaskan, lansia lebih rentan
SibSp	Numerik (int)	Jumlah saudara/pasangan di kapal	Ukuran keluarga memengaruhi keputusan evakuasi
Parch	Numerik (int)	Jumlah orang tua/anak di kapal	Idem, terkait dinamika keluarga
Fare	Numerik (float)	Harga tiket	Berkorelasi dengan kelas & lokasi kabin

Target variabel:

- Survived = 0 → Tidak Selamat
- Survived = 1 → Selamat

Preprocessing

1. **Hapus baris dengan nilai kosong (`dropna()`)** — terutama kolom **Age** yang sering kosong
2. **Encoding **Sex**** — ubah teks menjadi angka: **male** → 0, **female** → 1
3. **Tidak ada fitur tambahan (**feature engineering**)** — sengaja disederhanakan untuk keperluan pembelajaran

Distribusi Data (estimasi dari dataset standar)

Keterangan	Jumlah
Total penumpang (dataset)	~891
Setelah <code>dropna()</code>	~714
Data training (80%)	~571
Data testing (20%)	~143


Kategori	Persentase
Tidak Selamat (0)	~61%
Selamat (1)	~39%

Dataset ini **imbalanced** — lebih banyak yang tidak selamat. Ini merupakan refleksi dari kejadian nyata.

2. Model: Random Forest Classifier

Apa itu Random Forest?

Random Forest adalah algoritma **ensemble learning** yang membangun banyak decision tree secara paralel, lalu menggabungkan hasil prediksi masing-masing tree melalui voting mayoritas.



Konfigurasi Model

```
RandomForestClassifier(
    n_estimators=100, # 100 decision tree
    random_state=42   # seed untuk reproduibilitas
)
```

Parameter	Nilai	Penjelasan
<code>n_estimators</code>	100	Jumlah tree — semakin banyak, semakin stabil (tapi lebih lambat)
<code>random_state</code>	42	Seed random — hasil training selalu sama setiap dijalankan

Preprocessing: StandardScaler

Sebelum masuk ke model, semua fitur dinormalisasi menggunakan `StandardScaler`:

```
X_scaled = (X - mean) / std_deviation
```

Ini penting karena:

- Fitur seperti `Fare` (0–512) jauh lebih besar skala-nya dari `Pclass` (1–3)
- Mencegah fitur bernilai besar mendominasi hasil prediksi

Performa Model

Menggunakan train-test split 80:20 dengan `random_state=42`:

Metrik	Nilai (estimasi)
Accuracy	~82–85%
Precision (Selamat)	~80–84%
Recall (Selamat)	~75–80%
F1-Score	~78–82%

Nilai persis bervariasi tergantung versi dataset. Lihat output `python train.py` untuk nilai aktual.

Mengapa Random Forest?

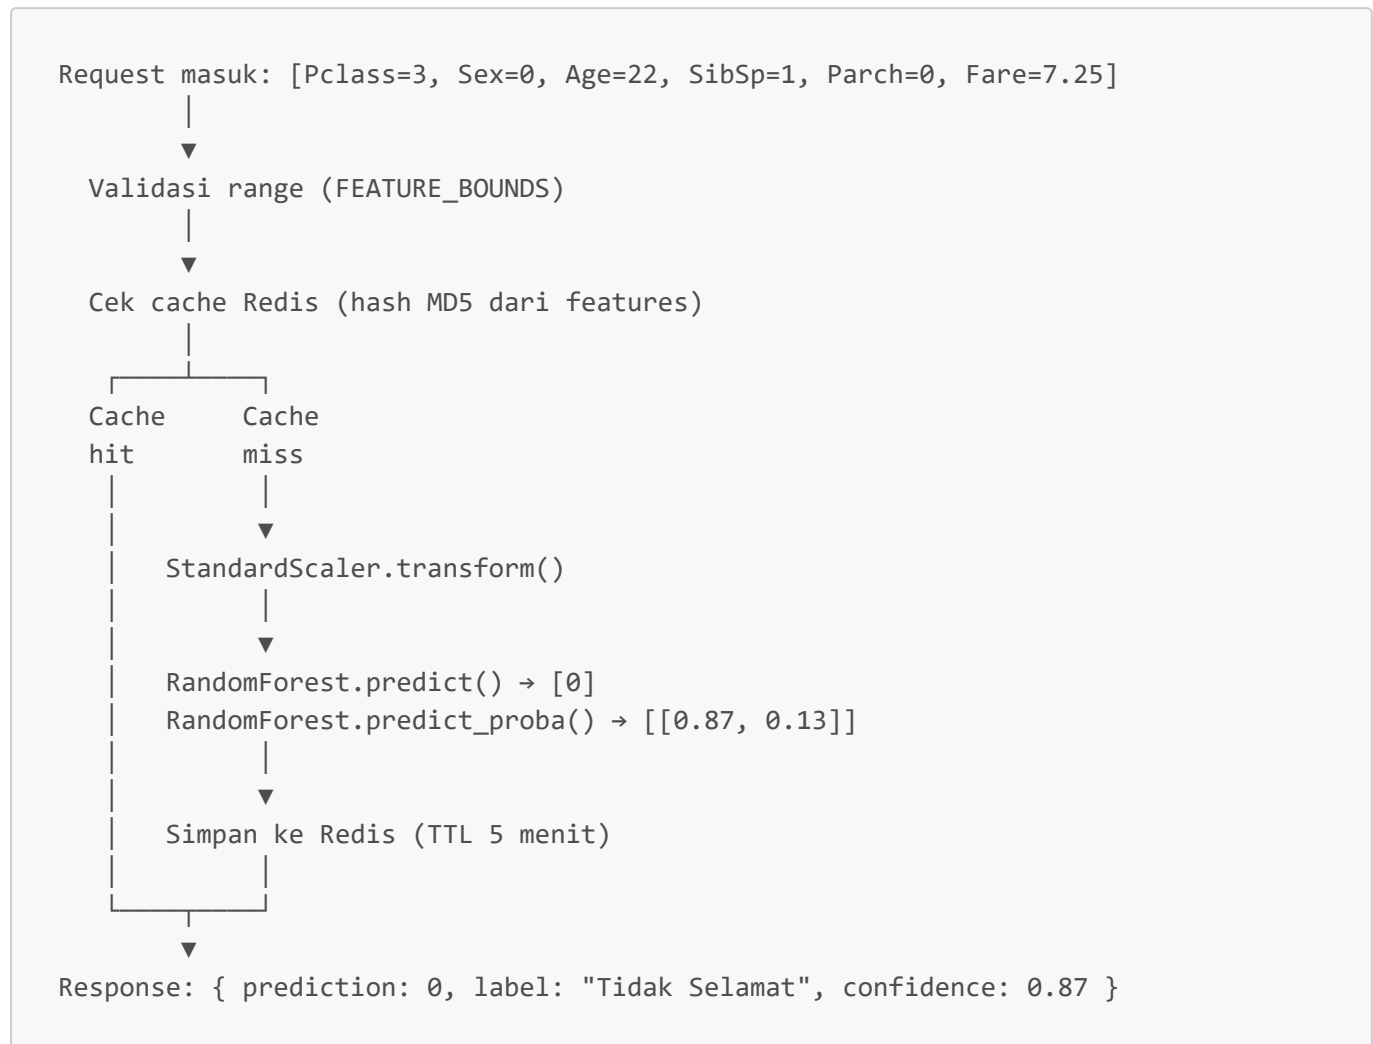
Keunggulan	Penjelasan
Akurasi tinggi	Umumnya lebih baik dari single decision tree
Robust terhadap outlier	Agregasi banyak tree meredam pengaruh outlier
Feature importance	Bisa melihat fitur mana yang paling berpengaruh
Tidak mudah overfit	Karena menggunakan banyak tree independen

Keunggulan**Penjelasan**

Mudah digunakan

Sedikit hyperparameter yang perlu diatur

3. Alur Inferensi



4. File Model yang Disimpan

File	Isi	Ukuran Estimasi
model/model.pkl	Object <code>RandomForestClassifier</code> terlatih	~5–15 MB
model/scaler.pkl	Object <code>StandardScaler</code> dengan mean & std dari data training	< 1 KB
model/classes.pkl	Label class: ["Tidak Selamat", "Selamat"]	< 1 KB

File `.pkl` menggunakan format binary Python (joblib). **Jangan buka file ini di production dari sumber tidak terpercaya** — `.pkl` bisa mengandung kode berbahaya.

5. Keterbatasan Model

1. **Dataset kecil** — hanya ~714 sampel setelah preprocessing
2. **Missing value dihapus** — bukan di-impute, sehingga kehilangan informasi
3. **Fitur terbatas** — fitur seperti **Cabin**, **Embarked**, **Ticket** diabaikan
4. **Tidak ada cross-validation** — hanya single train-test split
5. **Hyperparameter default** — belum dioptimasi dengan GridSearch/RandomSearch

Untuk production nyata, model ini perlu ditingkatkan dengan teknik seperti:

- Imputation untuk nilai yang hilang
- Feature engineering (misalnya ekstrak gelar dari nama: Mr, Mrs, Miss)
- Hyperparameter tuning
- Cross-validation untuk evaluasi yang lebih robust